# Ventas y pronóstico de productos de consumo

Entrega final de Ciencia de Datos

**Javier Bueno Sánchez**

SQL Server, Python y Power BI
Histórico: enero de 2022 a julio de 2023

18 de octubre de 2026

# Objetivo y relevancia del proyecto

Decisiones sobre surtido, cobertura comercial y planeación de ventas

## Pregunta de negocio

¿Dónde se concentra la venta y qué ritmo semanal puede esperarse para Vanish y Lysol?

## Herramientas y función

Python: calidad, exploración, clustering y modelos.

SQL Server: integración y consultas de negocio.

Power BI: consulta interactiva del desempeño.

# Base de datos y alcance del análisis

Cinco tablas de origen con claves de producto, semana y atributos

| Control | Resultado |
|---|---|
| Registros de ventas | 122,002 |
| Catálogo válido / productos con ventas | 503 / 350 |
| Semanas observadas | 80 |
| Áreas / agregado nacional | 6 / 1 |
| Categorías con ventas / en catálogo | 1 / 5 |

La fuente no documenta moneda ni escala. Los valores mantienen su unidad original.

# Limpieza y consolidación en Pandas

Validaciones antes de transformar y unir las tablas

## Tratamiento aplicado

Dos productos sin ITEM quedan separados.

Identificadores en texto conservan ceros y sufijos.

Espacios, categorías y fechas estandarizados.

Las uniones conservan los 122,002 hechos.

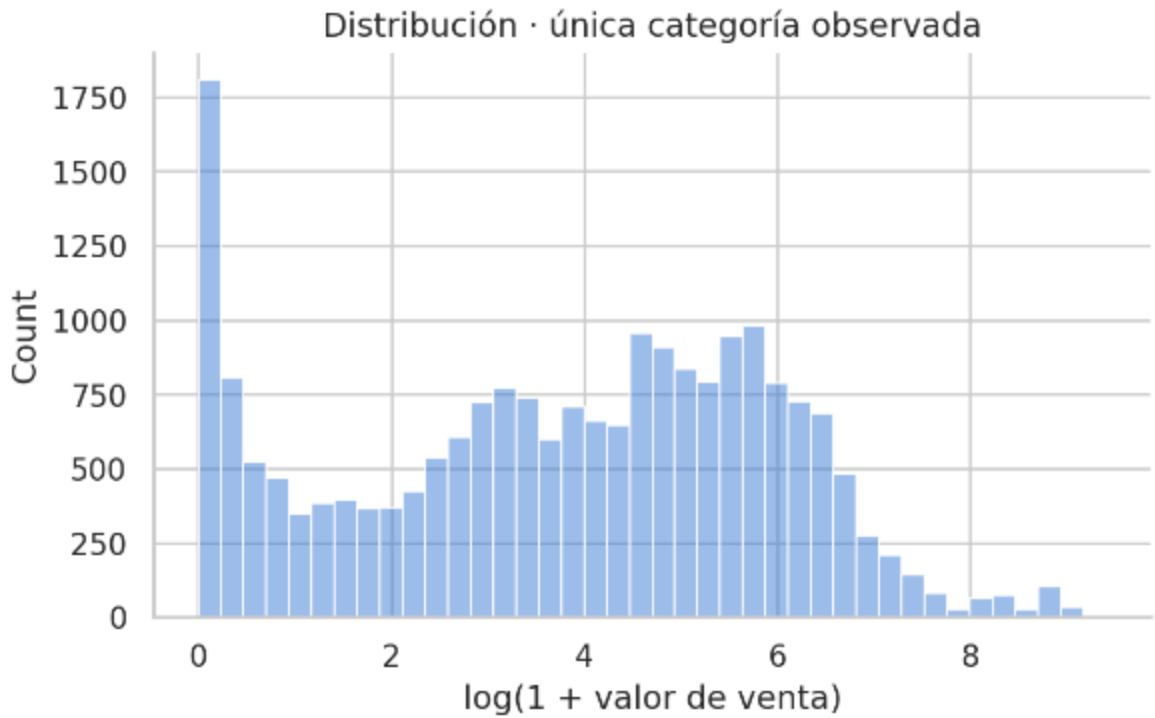
```
p = p.dropna(subset=['ITEM'])
assert p.ITEM.is_unique
assert t.WEEK.is_unique

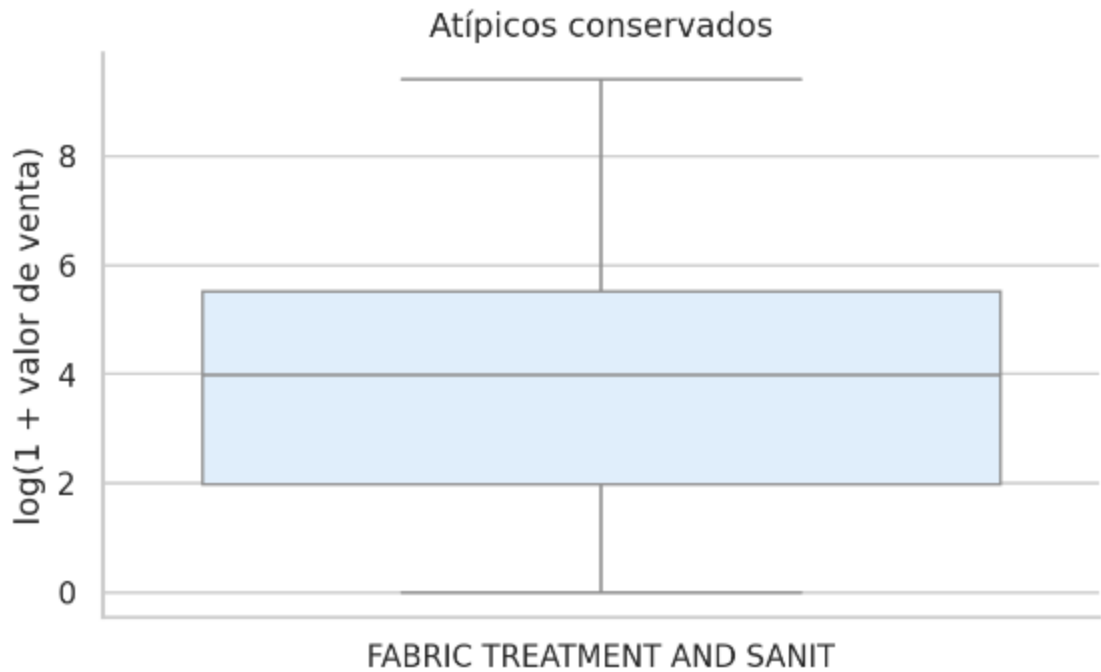
d = f.merge(
    p, left_on='ITEM_CODE',
    right_on='ITEM',
    validate='many_to_one'
)
assert len(d) == len(f)
```

La clave compuesta de DIM_SEGMENT evita multiplicar ventas en la unión por atributos.

# Distribución de ventas y valores atípicos

La única categoría observada limita la comparación entre categorías

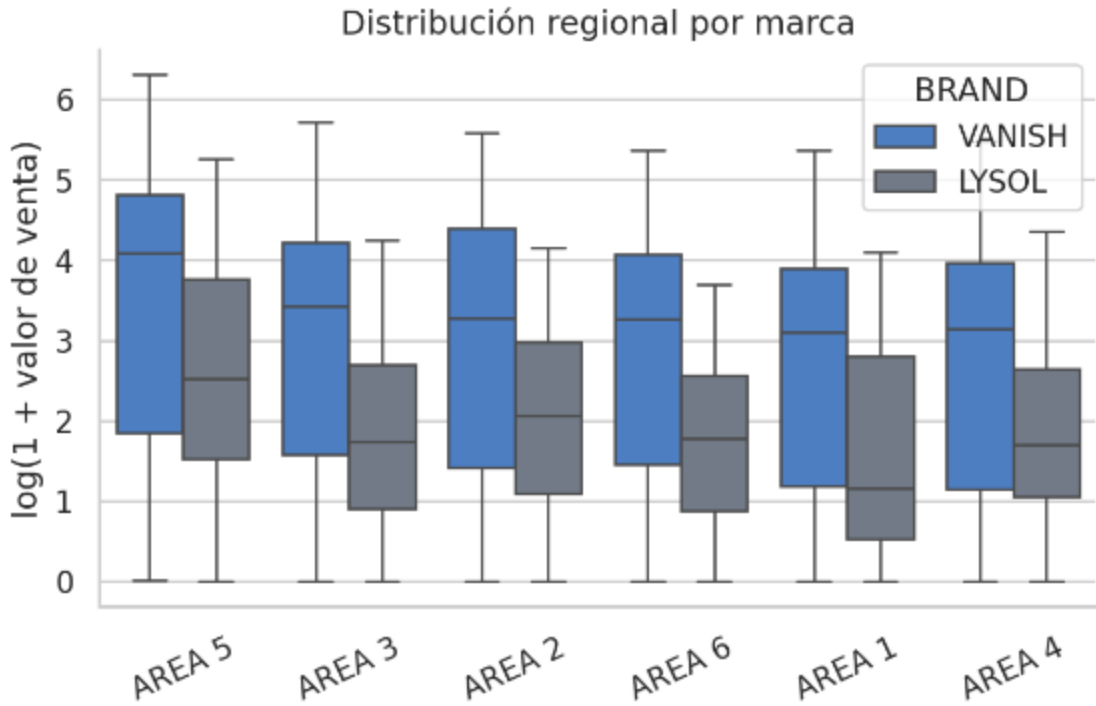


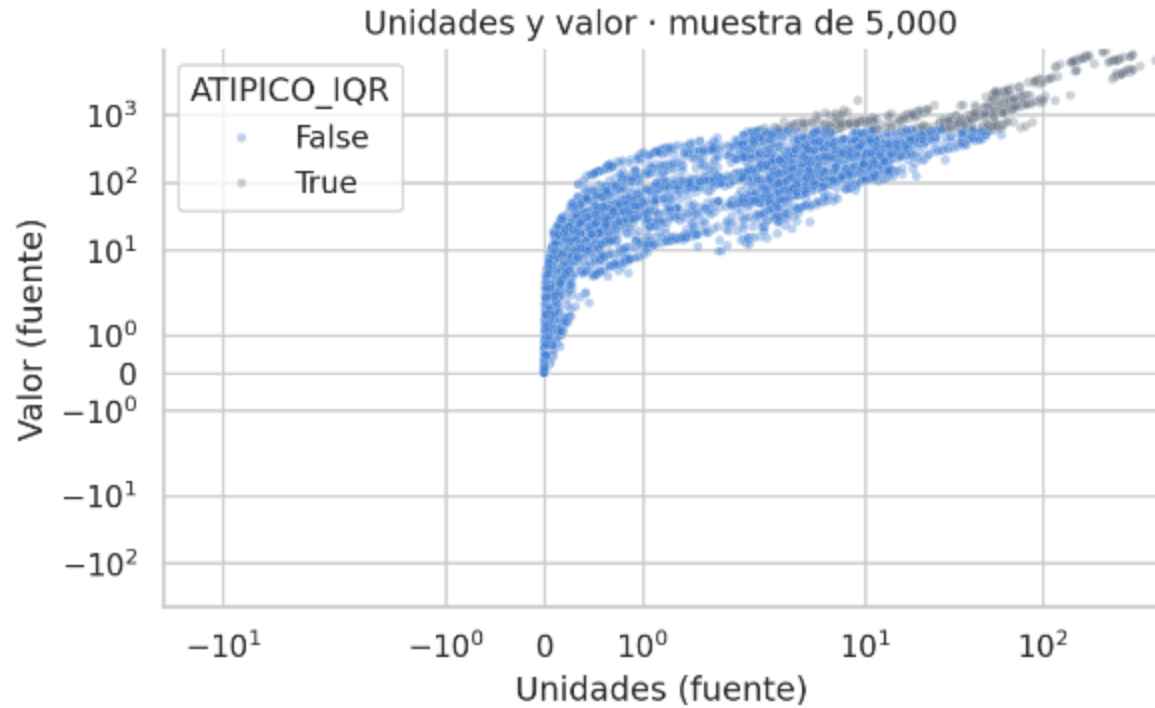




La distribución es asimétrica. IQR identifica casos para revisar y los extremos permanecen en la base.

# Dispersión regional y revisión de atípicos

Vanish y Lysol muestran escalas y distribuciones distintas



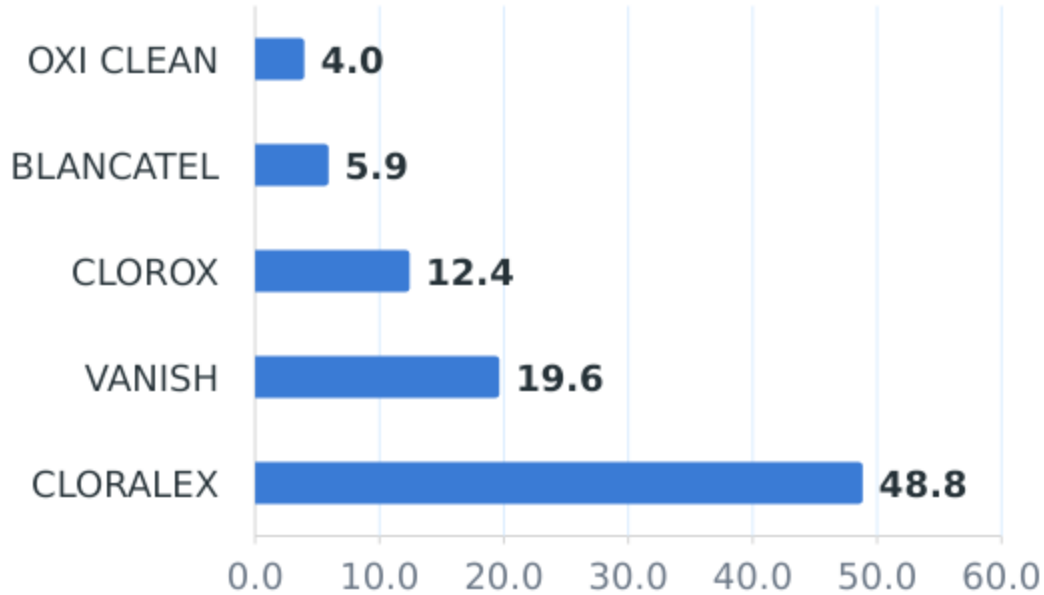




Un valor alto puede reflejar volumen comercial. Los gráficos por sí solos no prueban un error.

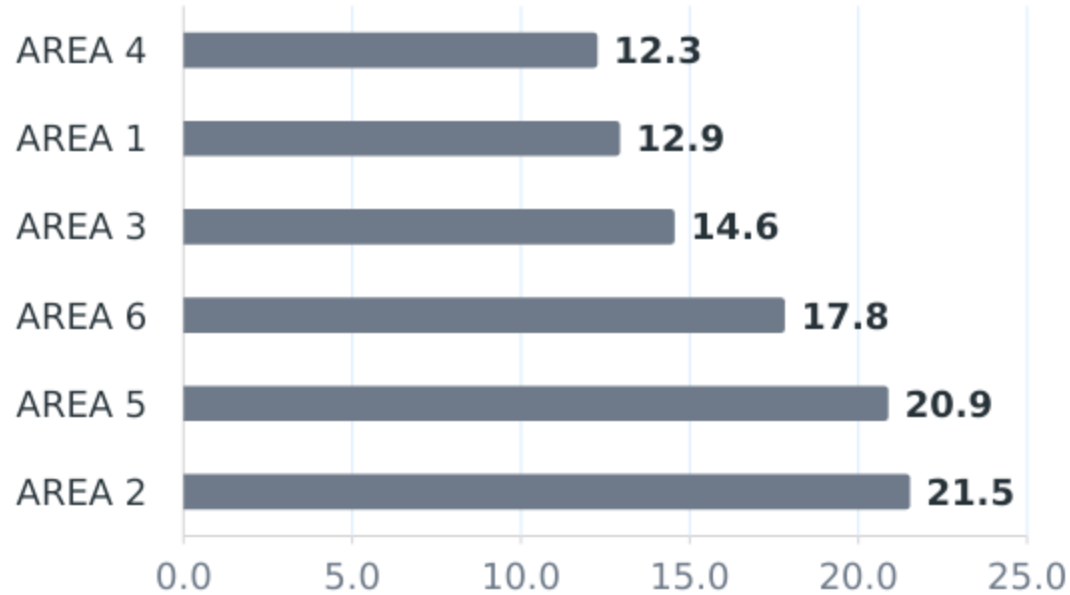
# Concentración comercial por marca y área

Participación en valor de ventas del periodo observado

## Marcas principales



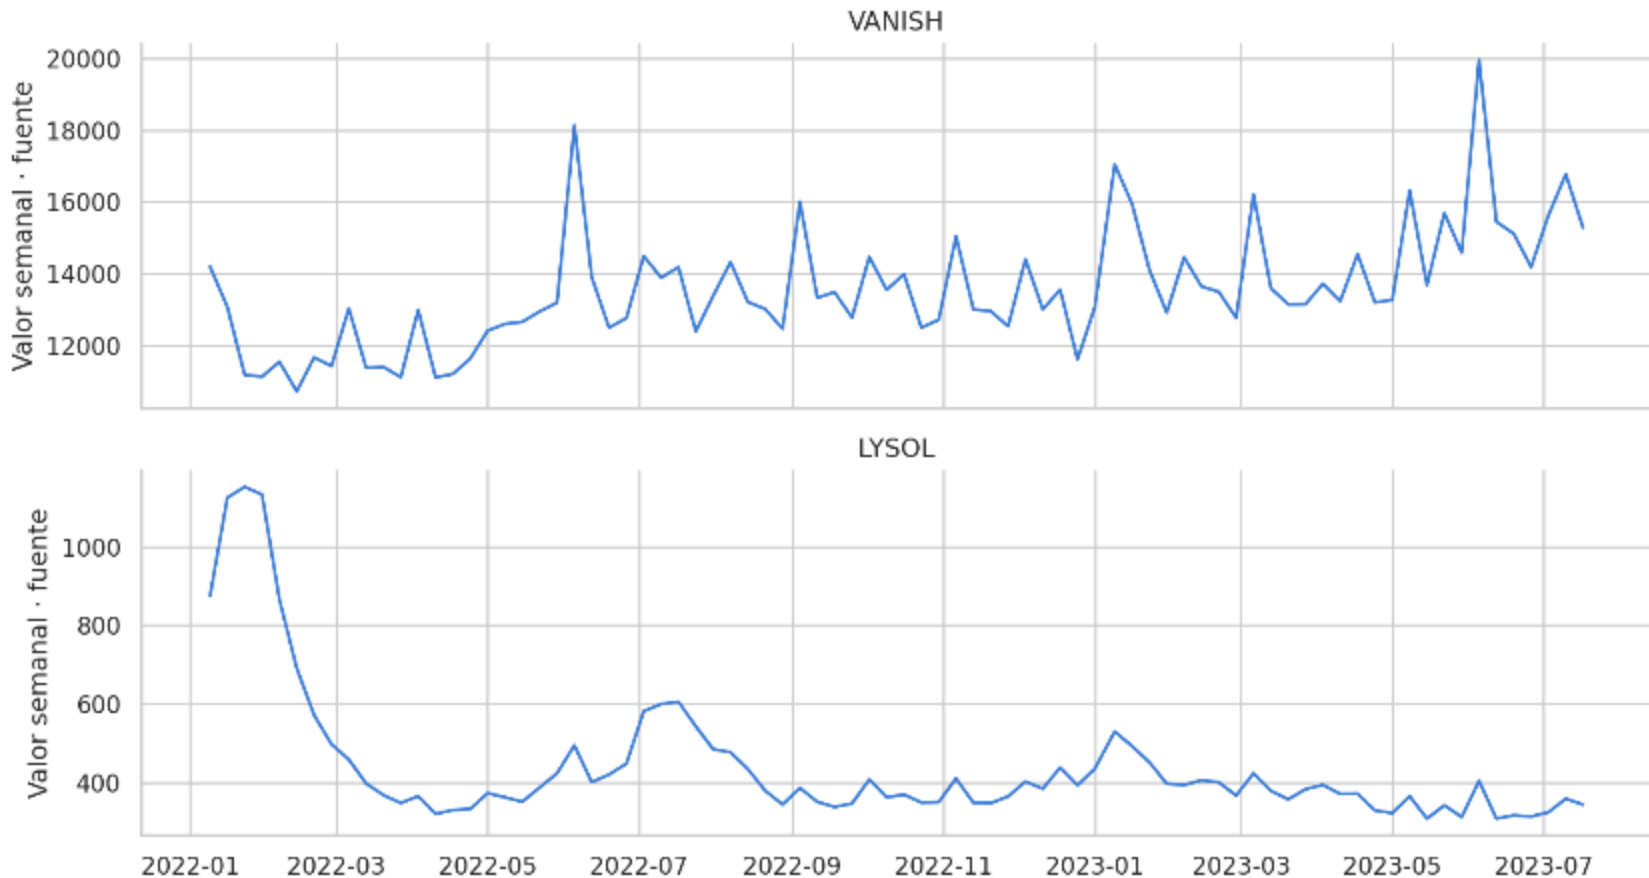

## Seis áreas, sin agregado nacional




Vanish representa 19.6% y Lysol 0.64% del valor nacional. Bleach aporta 68.7%.

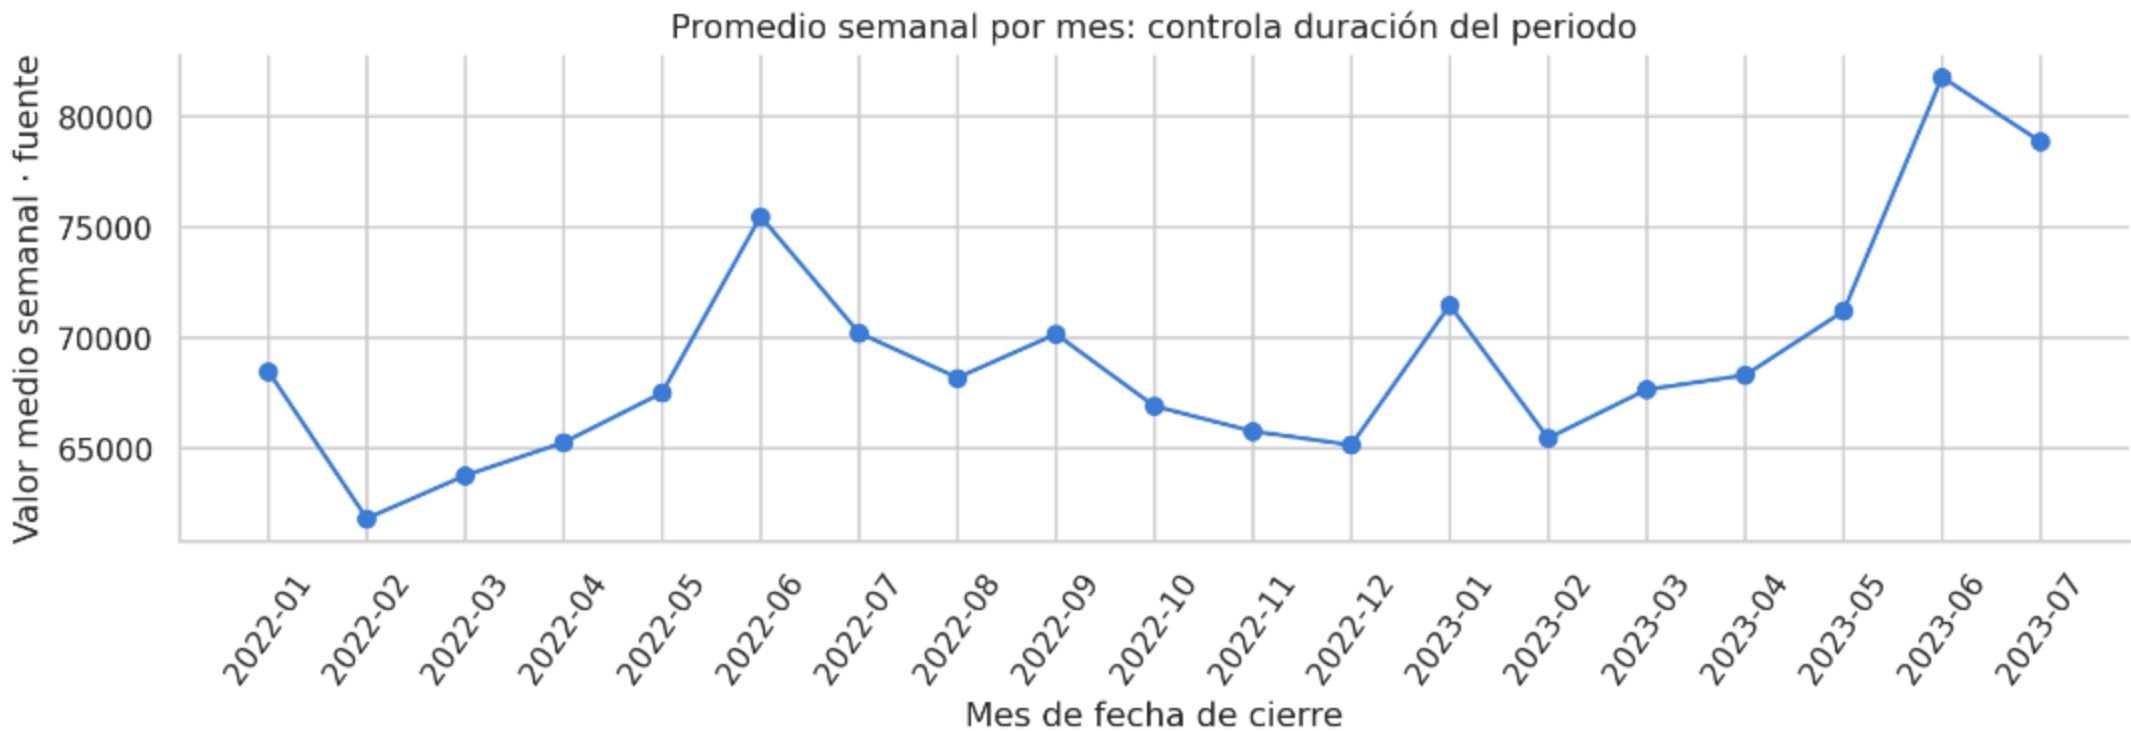
# Evolución semanal de Vanish y Lysol

Agregado nacional con etiquetas de marca exactas



# Promedio semanal por mes

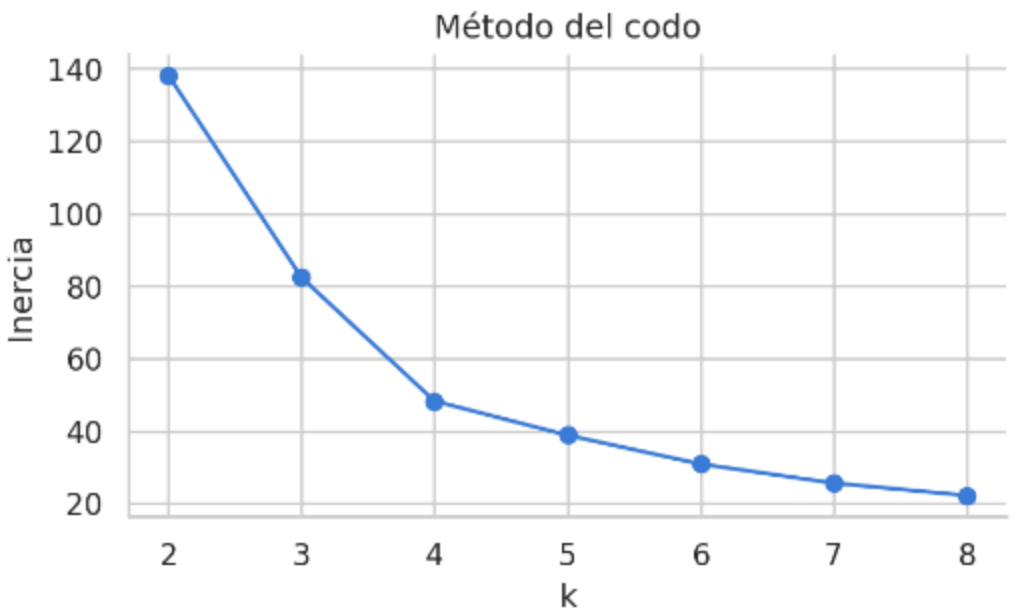
El promedio semanal controla meses de distinta duración




Julio de 2023 contiene solo tres semanas observadas. Su acumulado no debe compararse directamente con meses completos.

# K-Means: cuatro perfiles de productos Vanish

76 productos válidos de 77 observados. Silueta máxima: 0.4934





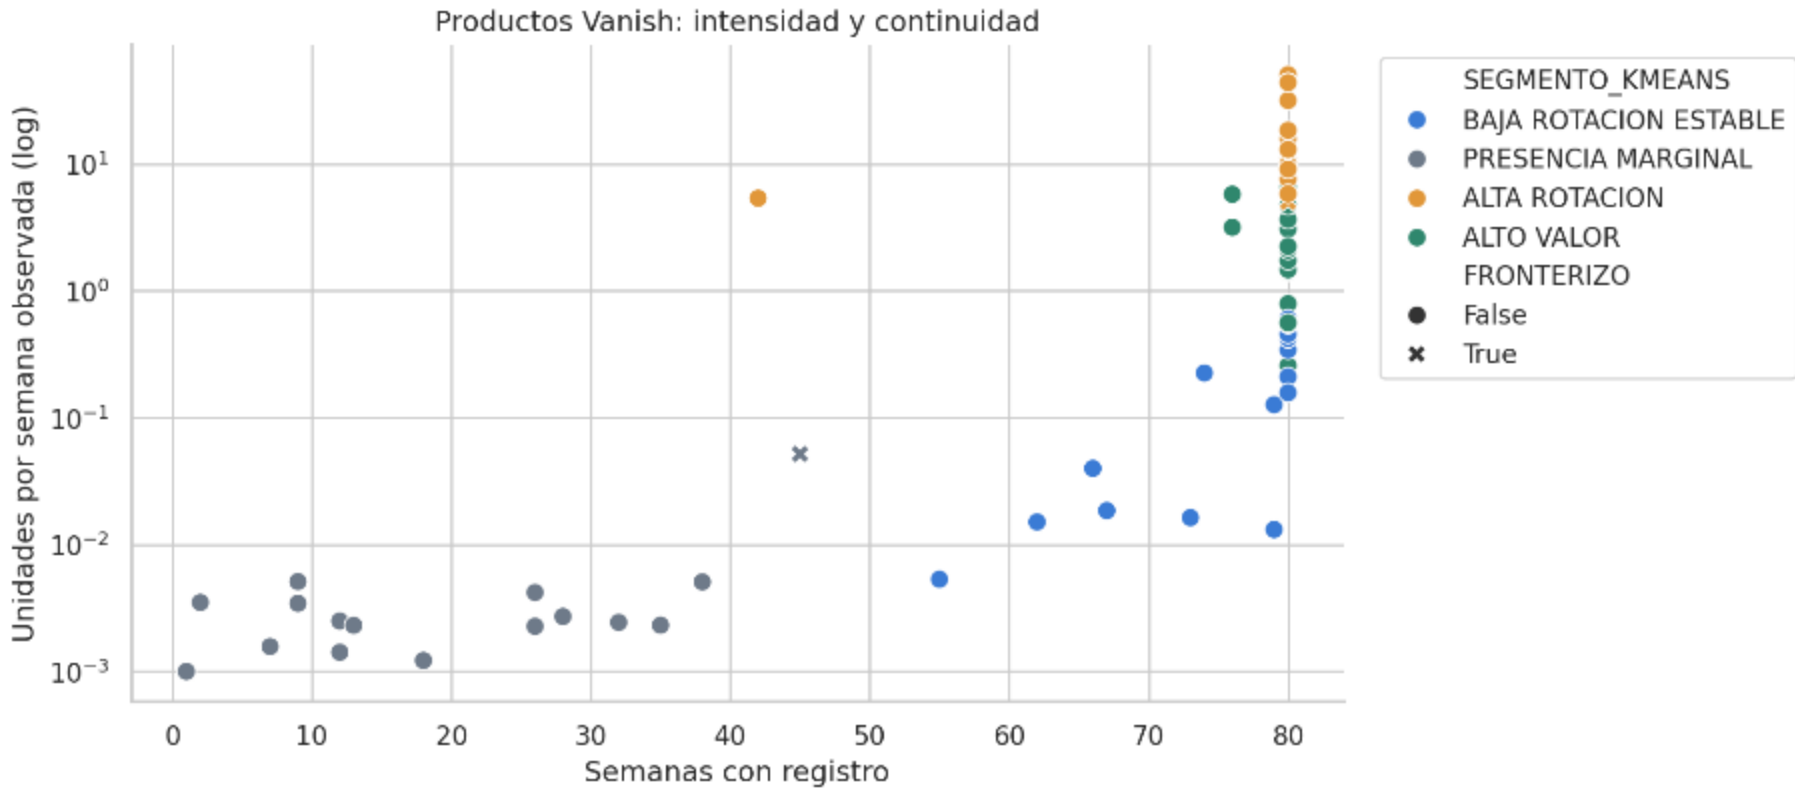


Intensidad y precio implícito con log1p. Continuidad sin transformar.

```
X = StandardScaler().fit_transform(datos)
KMeans(n_clusters=4, random_state=42, n_init=20).fit(X)
```

# Intensidad y continuidad de los productos

Las semanas con registro describen presencia en la base, sin acreditar disponibilidad




2 productos tienen silueta negativa y requieren revisión individual. El precio implícito no equivale a margen.

# Segmentos y acción comercial propuesta

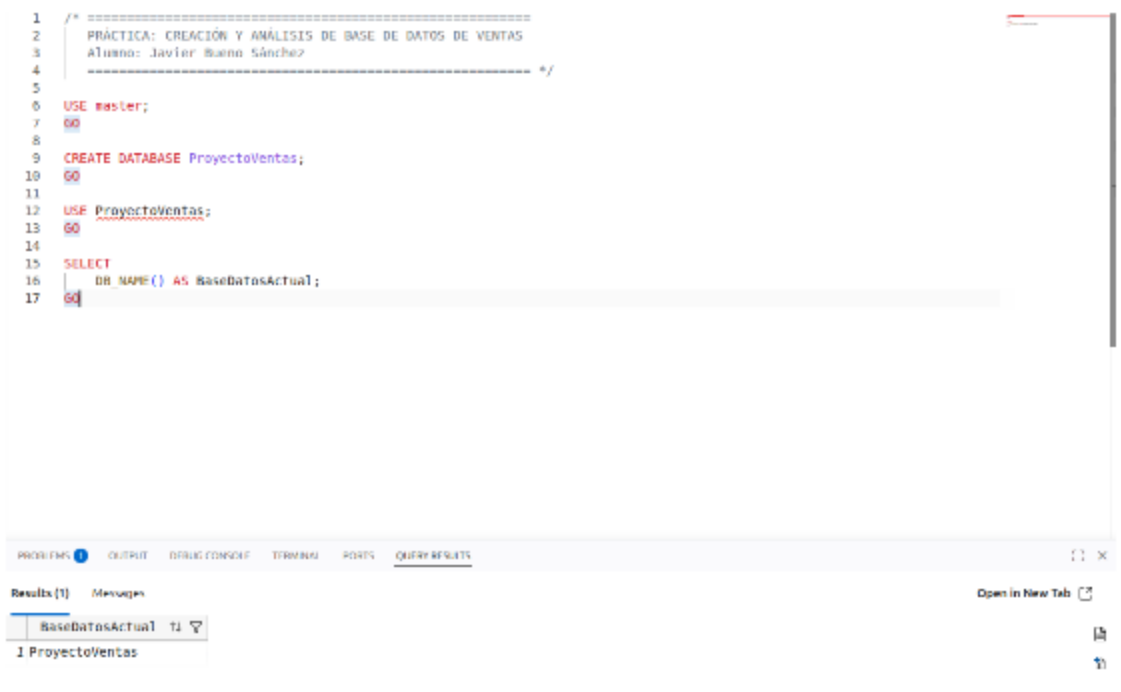
Participación sobre el valor de los 76 productos incluidos

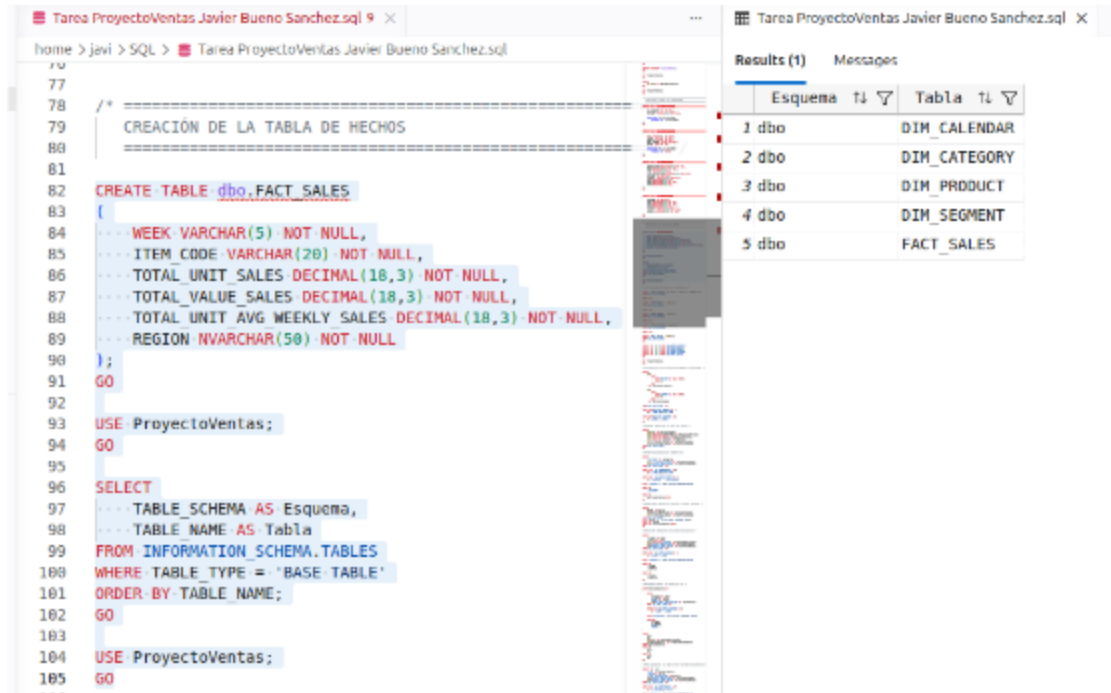
| Perfil | SKU | Valor % | Acción propuesta |
|---|---|---|---|
| ALTA ROTACION | 16 | 50.81 | Asegurar disponibilidad |
| ALTO VALOR | 24 | 48.17 | Revisar surtido y margen |
| BAJA ROTACION ESTABLE | 17 | 1.01 | Evaluar productividad por SKU |
| PRESENCIA MARGINAL | 19 | 0.01 | Comprobar cobertura y vigencia |

Alta rotación y alto valor concentran aproximadamente 99% de las ventas de Vanish incluidas. La evidencia no acredita rentabilidad.

# SQL Server: base relacional y carga

Capturas originales del entregable 4, con base, tablas y consultas ejecutadas

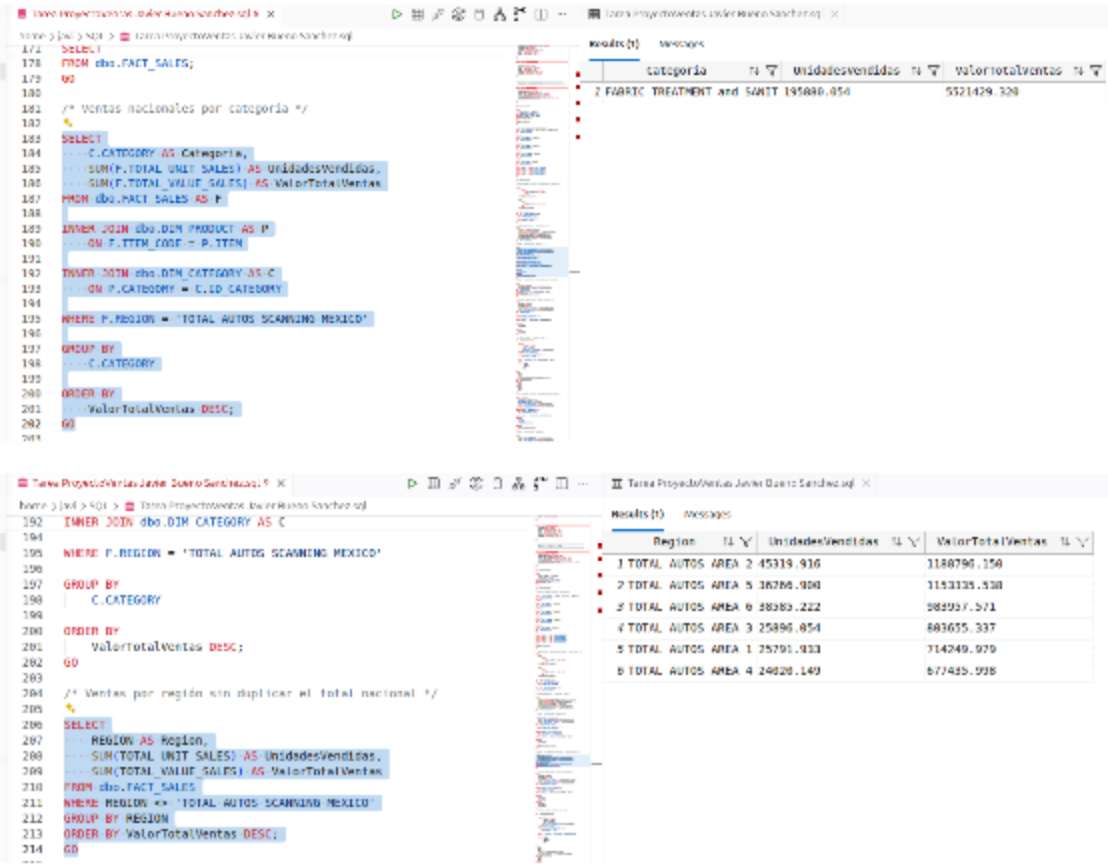



DIM_CATEGORY, DIM_PRODUCT, DIM_SEGMENT y DIM_CALENDAR contextualizan FACT_SALES. El paquete incluye el esquema y nueve consultas reproducibles.

# SQL: resultados por categoría y región

El filtro regional define el universo correcto de cada consulta

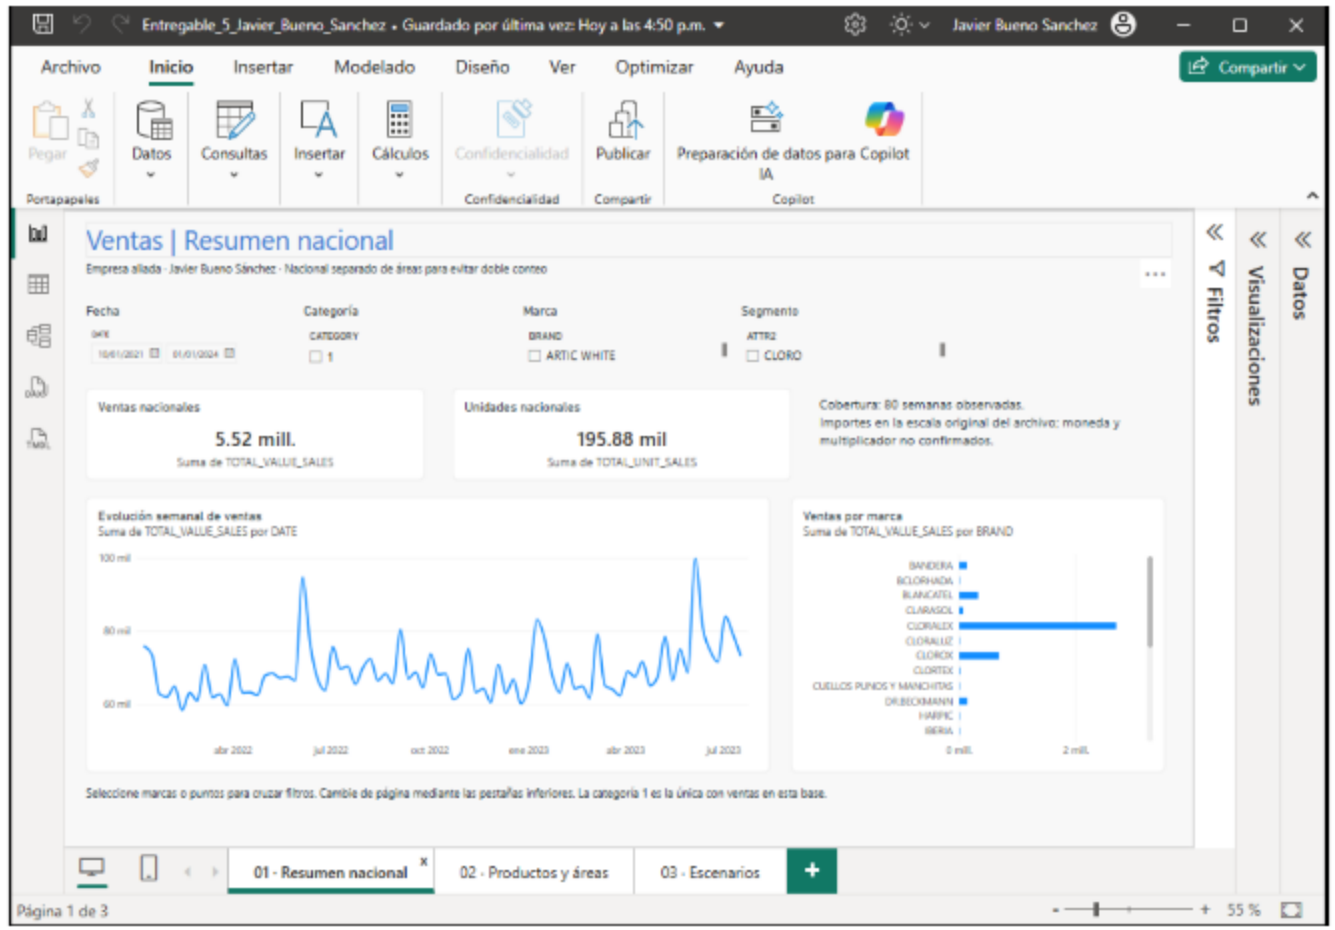


```
SELECT REGION,
 SUM(TOTAL_VALUE_SALES) AS Valor
FROM dbo.FACT_SALES
WHERE REGION <>
 N'TOTAL AUTOS SCANNING MEXICO'
GROUP BY REGION
ORDER BY Valor DESC;
```

**Las áreas 2, 5 y 6 lideran el valor. El total nacional permanece fuera del ranking regional.**

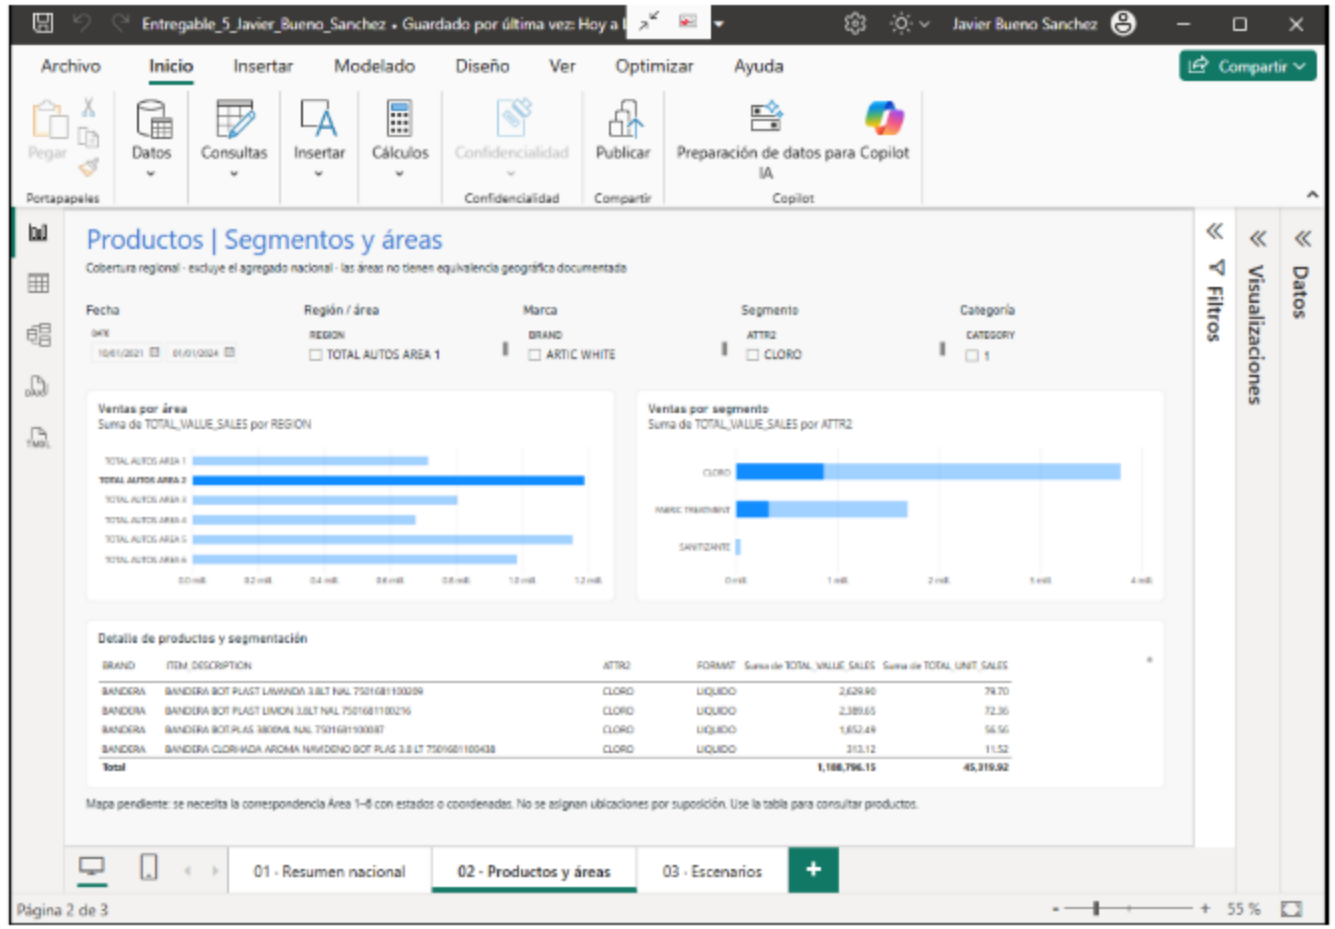
# Power BI: resumen nacional

Captura real del informe con indicadores, tendencia y ranking por marca



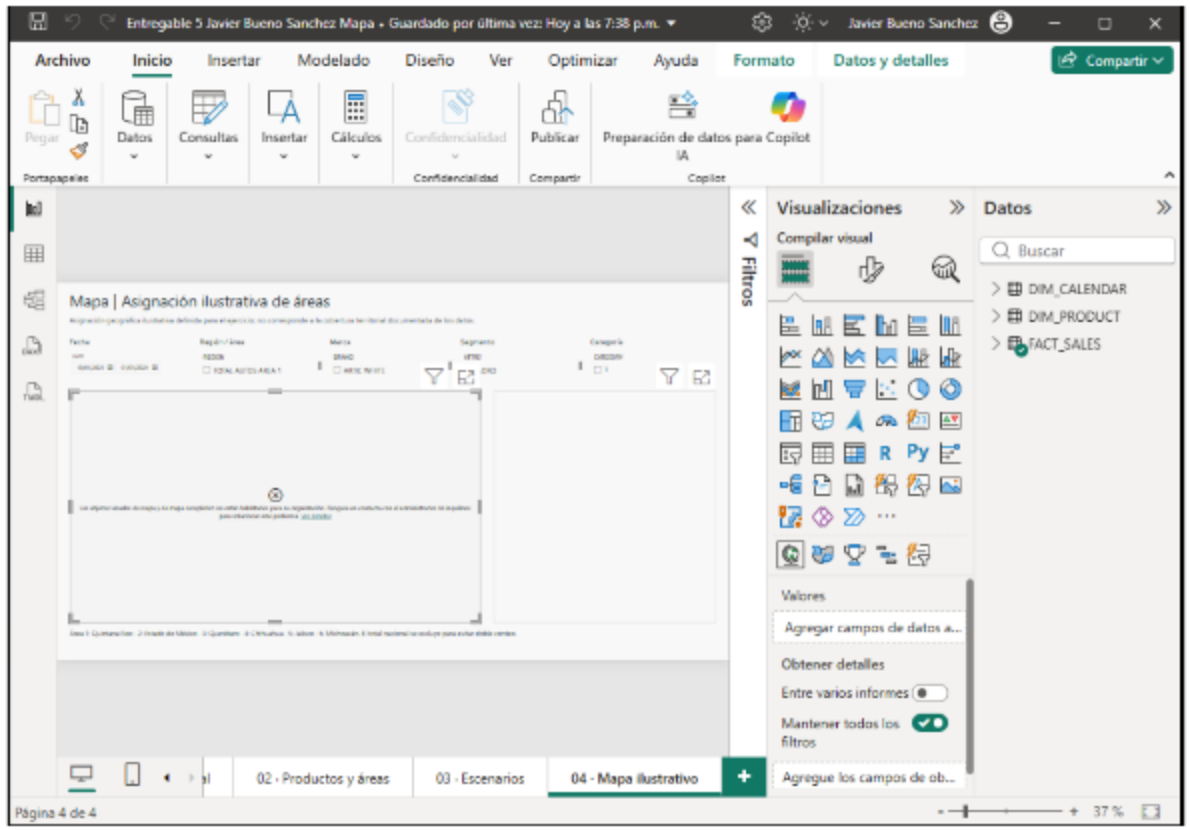
# Power BI: productos, segmentos y áreas

Segmentadores de fecha, región, marca, atributo y categoría



# Geografía ilustrativa y estado del mapa

La fuente aporta áreas comerciales, sin correspondencia documentada con estados




La asignación a seis estados sirve únicamente al ejercicio.

La captura muestra el bloqueo del servicio de mapas.

Los hallazgos usan áreas originales. La publicación no tiene enlace confirmado.

# Validación cronológica del pronóstico

Selección por MAE antes de abrir las últimas 12 semanas

| Etapa | Semanas | Uso |
|---|---|---|
| Entrenamiento | 1 a 56 | Ajustar candidatos |
| Validación | 57 a 68 | Elegir método y orden ARIMA |
| Prueba final | 69 a 80 | Medir desempeño independiente |
| Reentrenamiento | 1 a 80 | Pronosticar 15 semanas |

Candidatos: regresión múltiple, 16 órdenes ARIMA y dos referencias simples. Los ajustes que no convergen quedan descartados.

# Regresión múltiple y ARIMA en Python

Mismo horizonte de comparación y variables conocidas al pronosticar

## Regresión lineal múltiple

```
X = [t/52,
     sin(2*pi*t/52),
     cos(2*pi*t/52)]

fit = LinearRegression().fit(
    X_train, y_train
)
pred = fit.predict(X_future)
```

## Series de tiempo ARIMA

```
fit = ARIMA(
    y_train, order=(p,d,q),
    trend='c' if d==0 else 'n'
).fit()
pred = fit.forecast(12)

MAE = mean(abs(real - pred))
MSE = mean((real - pred)**2)
```

La regresión prueba términos anuales con poco histórico. No incorpora precios o promociones futuras.

# VANISH: error en las 12 semanas de prueba

Método fijado en validación: ARIMA(1, 0, 2)

| Modelo | MAE | MSE | RMSE | MAPE % |
|---|---|---|---|---|
| Ultima semana | 2,299.0 | 8,074,241 | 2,841.5 | 13.9 |
| Media 4 semanas | 1,890.8 | 6,111,683 | 2,472.2 | 11.3 |
| Regresión múltiple | 1,166.7 | 3,158,389 | 1,777.2 | 7.0 |
| ARIMA(1, 0, 2) | 2,130.9 | 7,237,144 | 2,690.2 | 12.9 |

**La regresión logra menor error en prueba, aunque ARIMA ganó en validación. Esta inestabilidad exige evaluar nuevos cortes temporales.**

# LYSOL: error en las 12 semanas de prueba

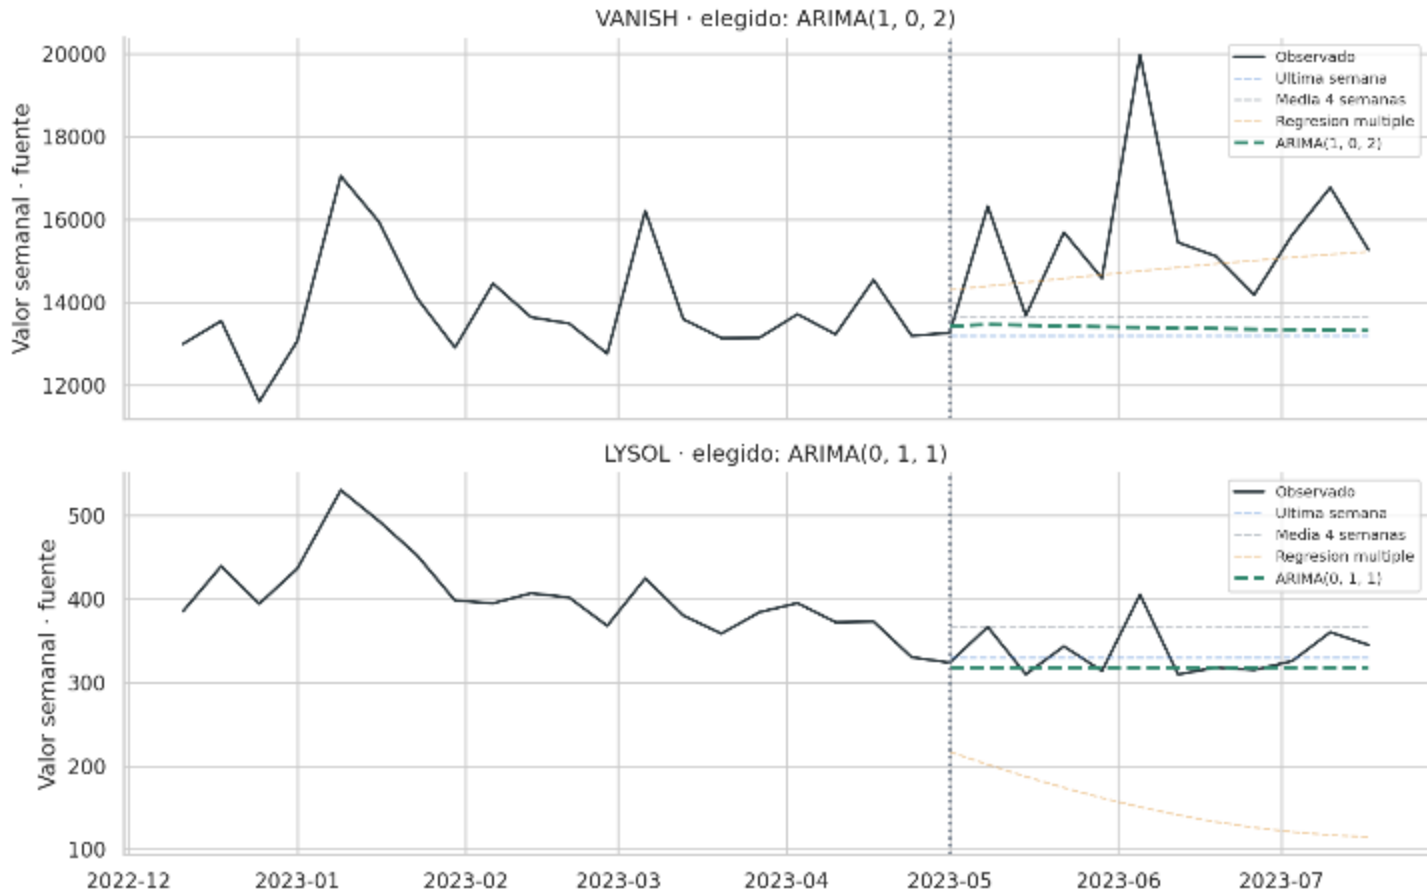
Método fijado en validación: ARIMA(0, 1, 1)

| Modelo | MAE | MSE | RMSE | MAPE % |
|---|---|---|---|---|
| Ultima semana | 22.1 | 819 | 28.6 | 6.3 |
| Media 4 semanas | 37.6 | 1,763 | 42.0 | 11.6 |
| Regresión múltiple | 182.7 | 35,281 | 187.8 | 54.0 |
| ARIMA(0, 1, 1) | 22.3 | 1,112 | 33.3 | 6.1 |

**La última semana iguala y supera ligeramente a ARIMA por MAE. El modelo complejo no acredita una ventaja operativa clara.**

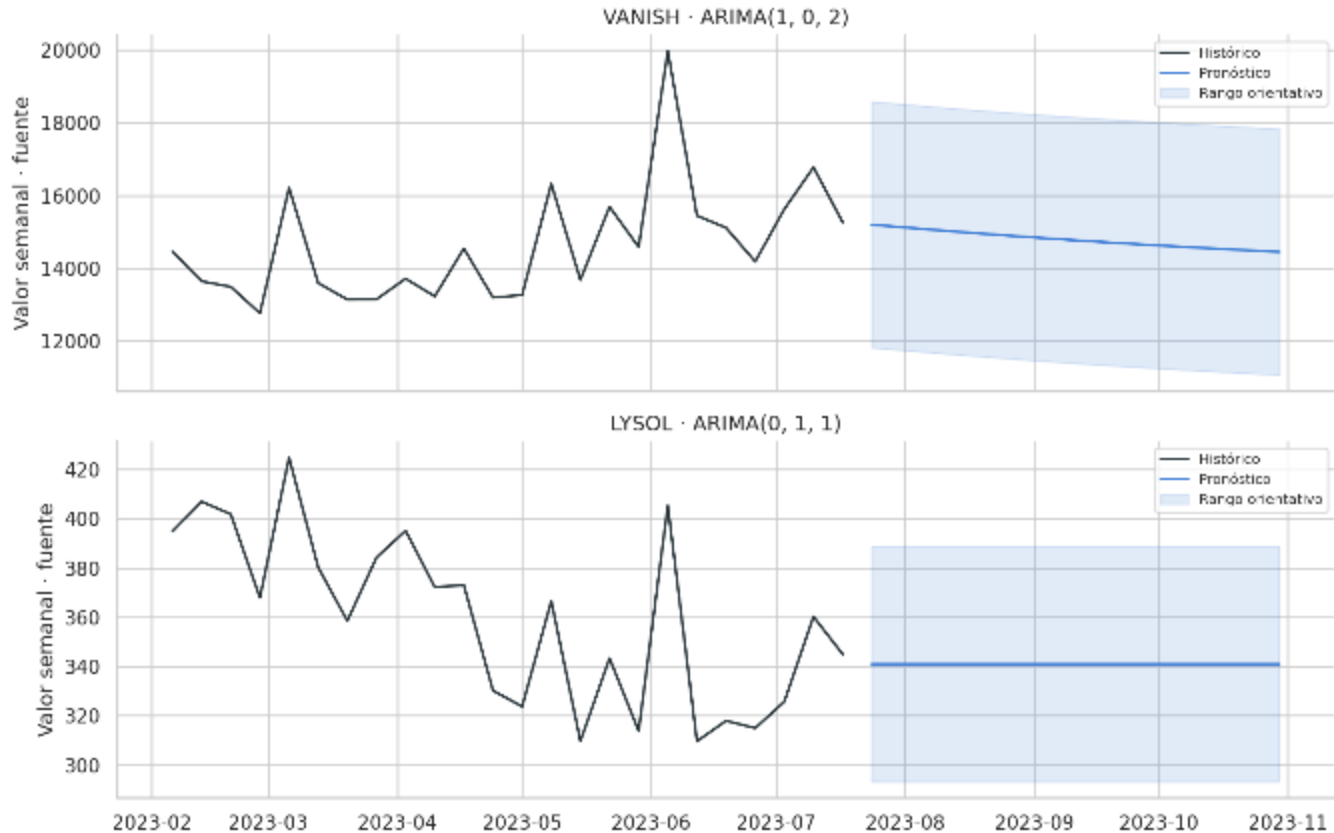
# Observado y predicho en prueba

El corte cronológico permanece fuera del entrenamiento y de la selección



# Pronóstico histórico hasta octubre de 2023

15 semanas posteriores al último cierre disponible, el 17 de julio de 2023




Rangos orientativos según 12 errores de prueba. No tienen cobertura garantizada y no crecen con el horizonte.

# Totales pronosticados por mes de cierre

La cantidad de semanas explica parte de la diferencia entre totales mensuales

| Mes | Semanas | Vanish | Lysol |
|---|---|---|---|
| 2023-08 | 4 | 59,887.2 | 1,364.0 |
| 2023-09 | 4 | 58,981.3 | 1,364.0 |
| 2023-10 | 5 | 72,671.1 | 1,705.0 |

Octubre agrupa cinco cierres semanales. Agosto y septiembre agrupan cuatro. Los totales representan la unidad original del valor de ventas.

El notebook y los CSV incluyen las 15 semanas y los promedios semanales por mes.

# Conclusiones y recomendaciones

Prioridades de negocio respaldadas por el análisis

## Surtido y cobertura

Los 40 SKU de alta rotación y alto valor concentran casi 99% del valor Vanish segmentado. Priorizar disponibilidad y revisar margen por producto.

Las áreas 2, 5 y 6 concentran la mayor participación. Investigar cobertura antes de atribuir diferencias a demanda.

## Pronóstico y siguientes pasos

La prueba final muestra inestabilidad del ranking de modelos. Mantener referencias simples y ampliar la validación con origen móvil.

Incorporar inventarios, precios, promociones y costos. El pronóstico de valor requiere una conversión por SKU antes de planear pedidos.

# Trazabilidad y alcance de la entrega

Material para revisar resultados y reproducir el análisis

## Entrega técnica

Notebook ejecutado con gráficos y explicaciones.

Datos originales y exportaciones limpias.

Consultas SQL Server y capturas originales.

PBIX y archivos CSV de métricas, clusters y pronóstico.

## Límites que afectan la decisión

Histórico de 2022–2023 y unidad monetaria sin acreditar.

Una sola categoría con ventas y territorios estatales ilustrativos.

Mapa pendiente de servicio y publicación sin enlace confirmado.

Modelos sin evidencia suficiente para automatizar pedidos.