# Módulo 51 | Regresión lineal múltiple

Javier Bueno Sánchez · Análisis de precios de viviendas mediante matrices

## Problema y preparación

Objetivo: estimar el precio (USD) a partir de características de viviendas de King County. La base contiene 21 613 registros y 21 columnas, sin datos faltantes. Se reservó el 20% para prueba (semilla 42). La selección de variables se hizo únicamente en entrenamiento.

Se excluyeron id, date, zipcode y yr_renovated por su codificación o alcance; sqft_above y sqft_basement se excluyeron porque su suma equivale exactamente a sqft_living. La selección posterior retiró sqft_lot (p = 0,1196). Quedaron 13 predictores.

## Código: partición y selección

```
assert (df.sqft_living == df.sqft_above + df.sqft_basement).all()
variables_iniciales = ['bedrooms','bathrooms','sqft_living','sqft_lot','floors',
                       'waterfront','view','condition','grade','yr_built',
                       'lat','long','sqft_living15','sqft_lot15']
train, test = train_test_split(df, test_size=0.20, random_state=42)
print('Entrenamiento:', len(train), '| Prueba:', len(test))
print('Variables iniciales:', variables_iniciales)

variables = variables_iniciales.copy()
retiros = []
while True:
    reporte = sm.OLS(train.price, sm.add_constant(train[variables], has_constant='add')).fit()
    p = reporte.pvalues.drop('const')
    if p.max() <= 0.05:
        break
    candidata = p.idxmax()
    retiros.append((candidata, float(p.max())))
    variables.remove(candidata)
print('Retiradas (variable, valor p):', retiros)
print('Variables finales:', variables)
```

## Estimación matricial

Con intercepto, se minimiza la suma de errores al cuadrado. Las ecuaciones normales son X■Xβ = X■y. Se emplea np.linalg.lstsq para resolver la matriz sin invertir X■X, operación numéricamente más estable.

```
X = np.column_stack([np.ones(len(train)), train[variables].to_numpy(dtype=float)])
y = train.price.to_numpy(dtype=float)
beta, residuo_lstsq, rango, singulares = np.linalg.lstsq(X, y, rcond=None)
assert rango == X.shape[1], 'La matriz de diseño carece de rango completo.'
residuo_normal = np.linalg.norm(X.T @ (y - X @ beta)) / (np.linalg.norm(X.T @ y) + 1e-15)
coeficientes = pd.Series(beta, index=['const'] + variables, name='Matriz (USD)')
print('Residuo relativo de ecuaciones normales:', f'{residuo_normal:.3e}')
display(coeficientes.to_frame().round(3))
```

La comparación automatizada se realizó con statsmodels.OLS sobre idénticas filas y variables.

## Bondad del ajuste: cálculo manual

```
ajuste_train = X @ beta
TSS = np.sum((y-y.mean())**2)
RSS = np.sum((y-ajuste_train)**2)
ESS = np.sum((ajuste_train-y.mean())**2)
n, k = len(y), len(variables)
r2_train = 1-RSS/TSS
r2_aj = 1-(1-r2_train)*(n-1)/(n-k-1)
print(f'TSS={TSS:.5e}; ESS={ESS:.5e}; RSS={RSS:.5e}')
print('Error relativo TSS-(ESS+RSS):', f'{abs(TSS-ESS-RSS)/TSS:.3e}')
print(f'R² entrenamiento={r2_train:.5f}; R² ajustado={r2_aj:.5f}')
```

```
TSS=2.25891e+15; ESS=1.56716e+15; RSS=6.91757e+14
Error relativo TSS-(ESS+RSS): 1.015e-13
R² entrenamiento=0.69377; R² ajustado=0.69354
```

## Verificación y prueba

La diferencia entre los coeficientes y las predicciones matriciales frente a statsmodels es numéricamente despreciable. Estas son las métricas obtenidas sobre entrenamiento y prueba:

```
X_test = np.column_stack([np.ones(len(test)), test[variables].to_numpy(dtype=float)])
y_test = test.price.to_numpy(dtype=float)
pred = X_test @ beta
assert np.allclose(pred, reporte.predict(sm.add_constant(test[variables], has_constant='add')))
metricas = pd.DataFrame({'Entrenamiento': [r2_train, mean_absolute_error(y, ajuste_train), np.sqrt(
mean_squared_error(y, ajuste_train))],
                         'Prueba': [r2_score(y_test,pred), mean_absolute_error(y_test,pred), np.sqrt(
mean_squared_error(y_test,pred))]},
                        index=['R²', 'MAE (USD)', 'RMSE (USD)'])
display(metricas.round(3))
umbral = train.price.quantile(.90)
altas = y_test >= umbral
print(f'Precio alto: umbral percentil 90 entrenamiento = USD {umbral:,.0f};'
      f' observaciones prueba = {altas.sum()}; MAE = USD {mean_absolute_error(y_test[altas],pred[altas]):
,.0f}')
```

| Métrica | Entrenamiento | Prueba |
|---|---|---|
| R² | 0,69377 | 0,69429 |
| MAE (USD) | 125 471 | 128 326 |
| RMSE (USD) | 200 023 | 214 981 |

```
Precio alto: umbral percentil 90 entrenamiento = USD 885,000; observaciones prueba = 447; MAE = USD 345,483
```

La lectura principal es conjunta: el R² de prueba es cercano a 0,694 y el MAE es cercano a 128 326 USD. Un R² razonable no garantiza una valoración individual precisa. El RMSE penaliza más los errores grandes.

## Ecuación final

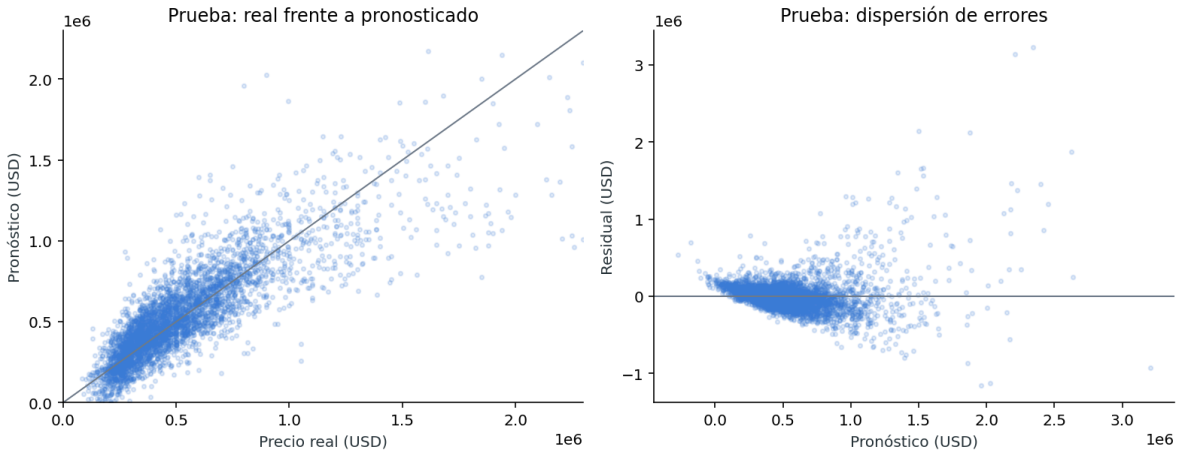
Precio estimado (USD) = intercepto + suma de cada coeficiente por su variable. Los coeficientes exactos se muestran en la siguiente página y en el notebook ejecutado.

## Coeficientes y contraste

| Variable | Matriz (USD) | statsmodels | Diferencia |
|---|---|---|---|
| const | -30,740,130.000 | -30,740,130.000 | 0.00000 |
| bedrooms | -33,426.150 | -33,426.150 | 0.00000 |
| bathrooms | 44,329.270 | 44,329.270 | 0.00000 |
| sqft_living | 166.805 | 166.805 | 0.00000 |
| floors | 14,163.620 | 14,163.620 | 0.00000 |
| waterfront | 577,832.700 | 577,832.700 | 0.00000 |
| view | 48,289.780 | 48,289.780 | 0.00000 |
| condition | 24,943.240 | 24,943.240 | 0.00000 |
| grade | 98,560.870 | 98,560.870 | 0.00000 |
| yr_built | -2,682.495 | -2,682.495 | 0.00000 |
| lat | 543,134.200 | 543,134.200 | 0.00000 |
| long | -77,536.420 | -77,536.420 | 0.00000 |
| sqft_living15 | 28.993 | 28.993 | 0.00000 |
| sqft_lot15 | -0.223 | -0.223 | 0.00000 |

El coeficiente negativo de bedrooms es una asociación condicionada por el tamaño y calidad, no un efecto causal. La interpretación de lat y long por grado tampoco equivale a un cambio típico de barrio.

## Diagnóstico y alcance




La dispersión de los residuos muestra errores de tamaño variable y el modelo lineal puede producir precios poco realistas para casos extremos. El MAE del segmento alto, calculado en el notebook, debe leerse junto al global.

La base contiene fechas de venta, pero este ejercicio no valida pronósticos futuros: se usó una partición aleatoria. Para predicción temporal habría que ordenar por fecha y evaluar sobre ventas posteriores.

Fuente: archivo facilitado kc_house_data.csv. Reproducibilidad y tabla completa de statsmodels en el notebook adjunto.