Módulo 52 | Pruebas de hipótesis

Javier Bueno Sánchez · Profesión Científico de Datos

Objetivo y método

Se analizaron 21,613 viviendas de King County. Se reservaron 4,323 observaciones (20%) para prueba y se seleccionaron variables usando solo 17,290 registros de entrenamiento. Precio en miles de USD. Se excluyeron ID, fecha, código postal numérico y las dos superficies que, junto a sqft_living, causan dependencia lineal exacta. Antigüedad = 2015 - yr_built; renovación = indicador binario.

Hipótesis y cálculo matricial

Para cada predictor: H0: beta = 0; H1: beta distinto de 0; alfa = 0.05, contraste bilateral. beta = (X transpuesta X) inversa X transpuesta y; var(beta) = SSE/(n-p) por (X transpuesta X) inversa; t = beta/error estándar. El cálculo usa sistemas lineales, evita invertir explícitamente para estimar beta y concuerda con statsmodels OLS.

Tres enfoques Stepwise

Hacia adelante: 14 predictores; 14 entradas y 0 salidas. Variables finales: bathrooms, age_2015, grade, sqft_living, lat, waterfront, view, bedrooms, condition, sqft_living15, long, renovated, sqft_lot15, floors. Ninguna variable salió.

Hacia atrás: 14 predictores; 0 entradas y 1 salidas. Variables finales: bedrooms, bathrooms, sqft_living, floors, waterfront, view, condition, grade, lat, long, sqft_living15, sqft_lot15, age_2015, renovated. Salieron: sqft_lot.

Bidireccional: 14 predictores; 14 entradas y 0 salidas. Variables finales: bathrooms, age_2015, grade, sqft_living, lat, waterfront, view, bedrooms, condition, sqft_living15, long, renovated, sqft_lot15, floors. Ninguna variable salió.

Resultado predictivo

Método	Variables	R^2 ajustado	R^2 prueba	MAE (USD)	RMSE (USD)
Hacia adelante	14	0.694	0.695	128,200	214,855
Hacia atrás	14	0.694	0.695	128,200	214,855
Bidireccional	14	0.694	0.695	128,200	214,855

El modelo documentado es **Hacia adelante**, con RMSE de prueba de 214,855 USD y R^2 de 0.695. Las diferencias pequeñas entre métodos no justifican afirmar una superioridad general.

Coeficientes y pruebas del modelo documentado

Variable	Coef. miles USD	t	p	IC 95% (miles USD)
intercepto	-36723.4898	-22.26	<0.0001	[-39956.777, -33490.203]
bathrooms	41.7617	11.63	<0.0001	[34.722, 48.801]
age_2015	2.5481	31.78	<0.0001	[2.391, 2.705]
grade	98.1115	41.49	<0.0001	[93.476, 102.747]
sqft_living	0.1668	44.60	<0.0001	[0.159, 0.174]
lat	545.8478	47.19	<0.0001	[523.177, 568.518]
waterfront	572.5892	29.14	<0.0001	[534.068, 611.110]
view	47.9282	20.51	<0.0001	[43.349, 52.508]

Variable	Coef. miles USD	t	p	IC 95% (miles USD)
bedrooms	-33.0799	-15.78	<0.0001	[-37.189, -28.971]
condition	27.2647	10.54	<0.0001	[22.196, 32.333]
sqft_living15	0.0300	7.94	<0.0001	[0.023, 0.037]
long	-81.2404	-6.24	<0.0001	[-106.756, -55.725]
renovated	42.8027	5.24	<0.0001	[26.793, 58.813]
sqft_lot15	-0.2266	-3.89	0.0001	[-0.341, -0.112]
floors	13.1645	3.69	0.0002	[6.168, 20.161]

Ecuación: precio previsto (miles USD) = -36723.490 + (41.762 × bathrooms) + (2.548 × age_2015) + (98.111 × grade) + (0.167 × sqft_living) + (545.848 × lat) + (572.589 × waterfront) + (47.928 × view) + (-33.080 × bedrooms) + (27.265 × condition) + (0.030 × sqft_living15) + (-81.240 × long) + (42.803 × renovated) + (-0.227 × sqft_lot15) + (13.164 × floors)

Diagnóstico y lectura crítica

Máximo VIF con intercepto: 4.98 (sqft_living). El VIF mide asociación entre predictores; Stepwise no garantiza eliminarla. Las pruebas p posteriores a selección son exploratorias. El contraste estadístico no mide causalidad ni el valor comercial de cada atributo. RMSE supera MAE cuando existen errores grandes. La validación aleatoria puede ser optimista para nuevas zonas o periodos; antes del uso profesional se debe probar una partición espacial o temporal y revisar casos extremos.

Fuente: kc_house_data.csv (Kaggle, viviendas de King County). Notebook adjunto con código, trazas completas, comparación matricial y reporte automatizado.