Proyecto final: metodologia de Ciencia de Datos en Orange

Prediccion de medicamento recomendado para pacientes con una misma enfermedad

Dataset

200 pacientes | 5 variables | 5 medicamentos

Objetivo

Comparar modelos y seleccionar el mejor predictor

Herramienta

Orange + validacion cruzada + calibracion

Fecha

28 de junio de 2026

1. Proyecto tradicional vs proyecto agil

Comparacion aplicada a proyectos de Ciencia de Datos

Proyecto tradicional

Secuencia lineal: definicion completa, desarrollo, prueba y entrega final. Funciona bien cuando el alcance es estable, los datos ya son conocidos y el costo de cambiar es bajo. En Ciencia de Datos suele ser rigido porque el valor aparece despues de explorar los datos.

Proyecto agil

Trabajo iterativo por ciclos cortos: cargar datos, explorar, modelar, medir, ajustar y comunicar avances. Es mas adecuado cuando el problema cambia, los datos tienen incertidumbre o se requiere aprendizaje con el usuario final.

Lectura ejecutiva: en Ciencia de Datos la metodologia agil reduce el riesgo de invertir semanas en un modelo que no responde a la pregunta real del negocio o del area medica.

Caso aplicativo: seleccion de medicamento

Ejemplo realista de proyecto de Ciencia de Datos

Problema

Predecir el farmaco mas apropiado para un paciente futuro con base en variables clinicas disponibles.

Datos

Edad, sexo, presion arterial, colesterol, relacion sodio-potasio y medicamento observado.

Modelo

Clasificacion multiclase: drugA, drugB, drugC, drugX y drugY.

Decision

Seleccionar el modelo con mejor exactitud y menor complejidad operativa.



Ventaja agil: permite mostrar resultados tempranos, validar si las variables tienen sentido clinico y ajustar rapidamente parametros/modelos.

Riesgo agil: si no se documenta bien, puede generar decisiones apresuradas o cambios constantes sin trazabilidad.

2. Exploracion inicial del dataset

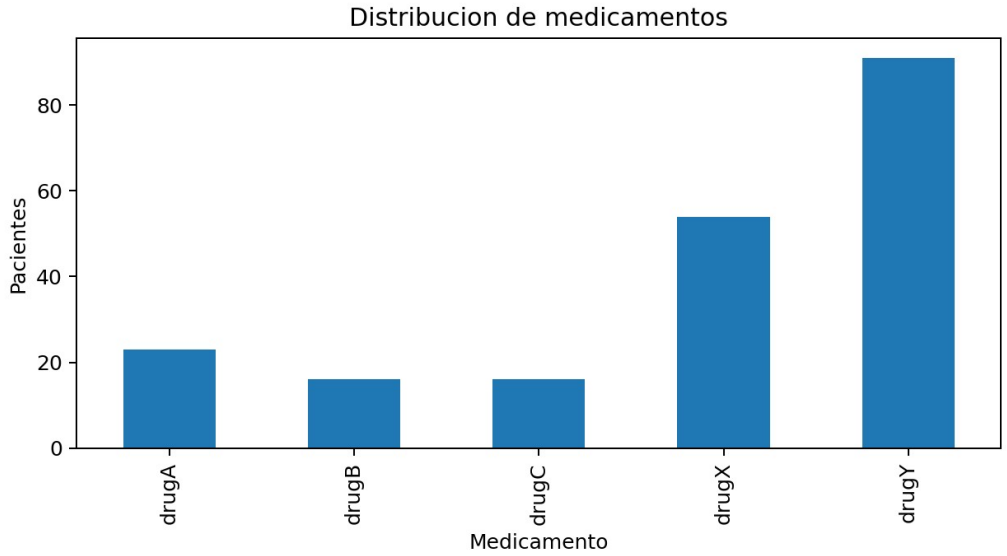
Estructura, calidad y variable objetivo

Registros
200 pacientes

Variables predictoras
Age, Sex, BP, Cholesterol, Na_to_K

Variable objetivo
Drug

Calidad
Sin valores faltantes detectados



La clase mayoritaria es drugY, por lo que un modelo ingenuo puede aparentar rendimiento sin aprender patrones clinicos.

Hay variables categoricas y numericas; Orange las procesa mediante widgets de preparacion y modelos de clasificacion.

La relacion Na_to_K tiene peso predictivo alto, especialmente para separar drugY.

3. Flujo propuesto en Orange

Modelo reproducible para carga, comparacion, evaluacion y prediccion

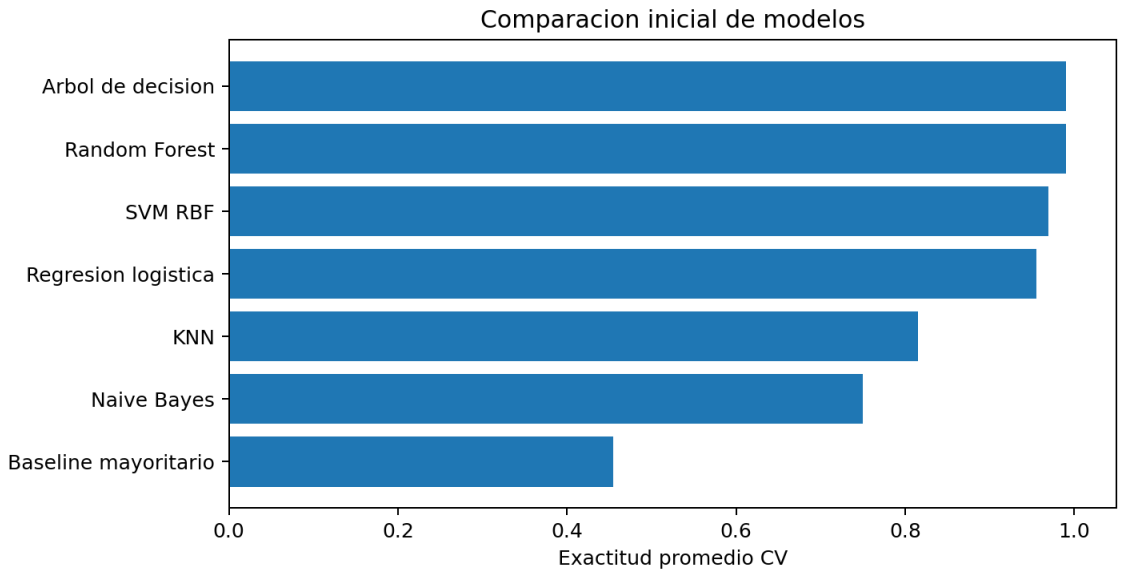


Archivo fuente incluido: flujo Orange base (.ows). Al abrirlo en Orange, debe vincularse el archivo drugs.csv si la ruta local cambia.

Criterio de comparacion: exactitud promedio por validacion cruzada; lectura adicional con matriz de confusion para revisar errores por clase.

4. Comparacion inicial de modelos

Validacion cruzada estratificada



Modelo	Exactitud media CV	Desv. est.
Arbol de decision	99.0%	1.2%
Random Forest	99.0%	1.2%
SVM RBF	97.0%	1.9%
Regresion logistica	95.5%	3.3%
KNN	81.5%	5.6%
Naive Bayes	75.0%	5.2%
Baseline mayoritario	45.5%	1.0%

Resultado: Arbol de Decision y Random Forest lideran con 99.0% promedio; ambos superan claramente al baseline de clase mayoritaria.

5. Calibracion de modelos

Busqueda de parametros para mejorar exactitud

Modelo	Mejor exactitud CV	Parametros
Random Forest	99.5%	max_depth: null, min_samples_leaf: 1, n_estimators: 50
Arbol de decision	99.0%	criterion: gini, max_depth: null, min_samples_leaf: 1
SVM RBF	97.0%	C: 1, gamma: 0.1
Regresion logistica	95.5%	C: 1
KNN	91.5%	n_neighbors: 9, weights: distance

Mejor combinacion: Random Forest con 50 arboles, profundidad libre y hoja minima de 1 registro; exactitud CV de 99.5%.

El Arbol de Decision conserva una ventaja operativa: es mas interpretable y casi igual de exacto.

6. Modelo recomendado

Balance entre exactitud, estabilidad e interpretacion

Recomendacion principal

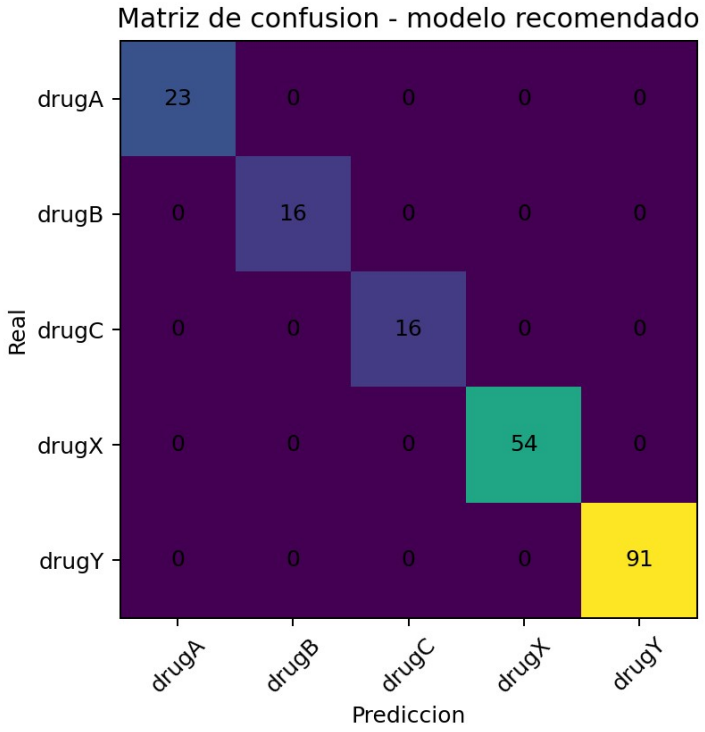
Random Forest calibrado

Exactitud estimada

99.5% en validacion cruzada

Uso operativo

Prediccion de farmaco para paciente nuevo



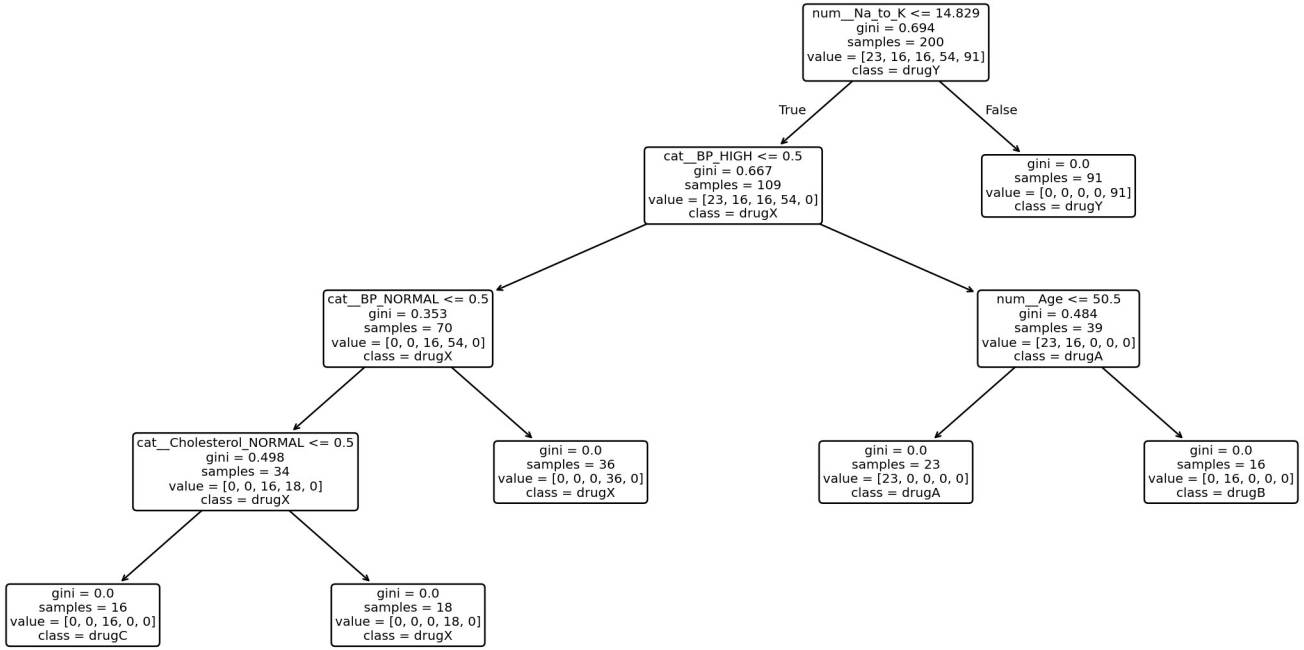
La matriz de confusion entrenada sobre el conjunto completo no muestra errores finales para el modelo recomendado.

La validacion cruzada es la metrica mas relevante porque estima desempeno con datos no vistos.

En un contexto medico, el modelo debe verse como soporte de decision, no como sustituto del criterio clinico.

7. Interpretacion de patrones

Reglas visibles mediante Arbol de Decision



Patron dominante: valores altos de Na_to_K orientan a drugY.

La presion arterial alta y la edad ayudan a separar drugA y drugB.

La presion baja con colesterol alto aparece asociada a drugC.

La presion normal o ciertos casos con colesterol normal tienden a drugX.

Este arbol sirve como explicacion ejecutiva; Random Forest se mantiene como recomendacion por mayor robustez.

8. Prediccion de pacientes futuros

Aplicacion del modelo recomendado

Caso	Age	Sex	BP	Cholesterol	Na_to_K	Prediccion	Confianza_modelo
Paciente 1	23	F	HIGH	HIGH	25.355	drugY	100.0%
Paciente 2	47	M	LOW	HIGH	10.114	drugC	100.0%
Paciente 3	50	M	HIGH	NORMAL	12.0	drugA	100.0%
Paciente 4	36	F	NORMAL	HIGH	9.0	drugX	100.0%
Paciente 5	65	F	LOW	NORMAL	20.0	drugY	100.0%

Nota de alcance: en las instrucciones recibidas no venia una tabla especifica de “siguientes casos”. Por eso se incluye una corrida demostrativa para documentar como debe interpretarse cada prediccion. Si se agregan casos reales, se sustituyen en el widget Predictions de Orange.

9. Ventajas y riesgos del enfoque agil

Aplicado al caso Orange

Ventajas

- Resultados tempranos y comparables.
- Permite probar varios modelos sin esperar al final.
- Facilita retroalimentacion del experto medico.
- Reduce desperdicio de esfuerzo cuando una variable no aporta valor.
- Genera aprendizaje documentado por iteracion.

Desventajas potenciales

- Riesgo de sobreajustar por probar demasiadas combinaciones.
- Puede faltar documentacion si solo se prioriza rapidez.
- Cambios frecuentes pueden confundir al usuario final.
- En medicina exige validacion externa, control etico y revision clinica.

10. Conclusiones y referencias

Cierre del proyecto final

Conclusiones

1. Trabajar de forma agil es mas conveniente en Ciencia de Datos porque permite iterar sobre datos, modelos y metricas con aprendizaje progresivo.
2. En el dataset analizado, Random Forest calibrado ofrece la mejor exactitud promedio: 99.5%.
3. El Arbol de Decision es el modelo mas explicable y funciona como soporte para justificar patrones ante usuarios no tecnicos.
4. Para uso medico real se requiere validacion con nuevos pacientes, supervision clinica y control de sesgos antes de tomar decisiones operativas.

Referencias

- Dataset drugs.csv proporcionado para la actividad.
- Orange Data Mining: widgets File, Test & Score, Confusion Matrix, Predictions.
- Scikit-learn usado como respaldo analitico para validar metricas y calibraciones.
- Conceptos de validacion cruzada, clasificacion multiclase y seleccion de modelos.